

Dispense sull'analisi delle componenti principali

Giorgio Marrubini e Camillo Melzi

Indice

	5
1 Dati multidimensionali	7
1.1 Rappresentazione matriciale e geometrica	7
1.2 Trasformazione delle variabili: centratura e standardizzazione	8
Bibliografia	9



Capitolo 1

Dati multidimensionali

1.1 Rappresentazione matriciale e geometrica

Tabella 1.1: Rappresentazione matriciale

Indiv.	X_1	X_2	\dots	X_p
1	x_{11}	x_{12}	\dots	x_{1p}
2	x_{21}	x_{22}	\dots	x_{2p}
\dots				
m	x_{m1}	x_{m2}	\dots	x_{mp}



1.2 Trasformazione delle variabili: centratura e standardizzazione

Indichiamo con $\bar{x}_1, \dots, \bar{x}_p$ le medie delle variabili X_1, \dots, X_p , cioè le p medie delle p colonne della Tabella 1.1, e con $\sigma_1^2, \dots, \sigma_p^2$ le rispettive varianze.

Il vettore $\bar{x} = (\bar{x}_1, \dots, \bar{x}_p)$ viene chiamato **baricentro**.

Centratura: semplice traslazione del baricentro nell'origine

$$x'_{ij} = x_{ij} - \bar{x}_j \quad (1.1)$$

- non perdo informazione sulla distanza tra i punti (la geometria della nuvola di punti rimane invariata)
- perdo solo informazione sul baricentro
- semplifica formule e conti (da ora in poi useremo sempre dati centrati)

Standardizzazione: questa trasformazione porta ogni variabile ad avere varianza 1 (in generale questa trasformazione viene fatta insieme alla centratura)

$$x'_{ij} = \frac{x_{ij} - \bar{x}_j}{\sigma_j} \quad (1.2)$$

- questa trasformazione rende le variabili degli scalari (numeri puri)
- questa trasformazione è necessaria quando si vogliono confrontare variabili con differenti unità di misura (le variabili devono essere omogenee per essere confrontabili)
- tutte le variabili hanno lo stesso “peso”
- cambia la distanza (la geometria) tra i punti. E' una dilatazione o contrazione.

Si veda la seguente figura per una rappresentazione grafica di dati centrati e scalati per una matrice di dati di 2 variabili

1.2. TRASFORMAZIONE DELLE VARIABILI: CENTRATURA E STANDARDIZZAZIONE⁹

